分形持续学习之前
large 实现审计与预注册的决定性比较

HUSHFUSION Forge 研究

2026 年 10 月

“暴力是无能者最后的手段。”
——阿西莫夫《基地》(1951)

摘要

持续学习通常被表述为固定计算图下的参数适应; 计算图本身是否应当生长——结构可塑性——是一个独立的问题, 常被断言而鲜被审计。我们构造了一个递归分形环学习器, 通过归一化凸门控混合根节点与后裔节点的输出, 并在改进减缓时生长后裔, 与固定单节点学习器配对运行于重采样输入的控制环境。评审后的实现审计揭示: 在原始 72,335 轮运行中, 后裔节点从未被训练——它们不出现于任何优化器的参数表, 所宣称的深度相关稀疏调度也从未进入任何调度判断——因此表面上的边界结果 “无结构优势” 并不是对分形学习器的检验。我们修复实现、配平梯度预算, 并预注册决定性比较。本文表明: 按预注册规则, 修复后的重跑 (200,000 轮, seed 20261012) 判为等价——warm 代价差的配对 95% bootstrap 置信区间完全落在 ± 1 步等价界内 ($n = 5{,}000$, CI $[-0.651, -0.548]$)。两个学习器的长程适应得到确认 (warm 代价从约 130 步降至约 9 步, 对照随机基线约 32 步), 生长可操作 (1 到 7 节点); 但在该确定性小模型 regime 下, 配平计算量时结构生长无可测优势。

1 引言

持续学习通常被表述为一个权重更新问题: 保持图结构固定, 调整参数, 使新任务被学习而不遗忘旧任务 [1, 3, 2]。这个框架留下了一个未被提出的问题: 当任务本身变化时, 应该改变的不仅是权重, 还有更新环路的组织吗? 对必须在数万轮中跟踪移动最优解的长程控制器而言, 答案至关重要; 然而结构生长是否有益, 几乎总是被断言, 而从未被测量。

我们把它当作一个测量问题。主实验让递归分形环学习器与固定单节点学习器在重采样输入的控制环境中配对运行 72,335 轮。评审后的审计发现: 分形树的子节点从未被训练, 所宣称的稀疏调度从未执行——长程运行检验的是门控未训练随机子网的根节点, 而非分形学习器。修复实现并配平梯度预算 (Forge commit `53e4938`) 后, 我们预注册判定规则并启动 200,000 轮的播种重跑。预注册判定是等价: 配对 bootstrap 置信区间完全落在 ± 1 步界内, 因此在该 regime 下、配平计算量时, 结构生长无优势。元学习 [1, 3]、持续整合 [2] 与分形分配 [6, 5] 的相关工作在节 4 总结; 什么成立、什么撤回、什么已判定, 是本文的完整主张集 (表 **??**)。

表 1: 预注册决定性重跑 (200,000 轮, seed 20261012, 配平计算量)。warm 行为推荐器, cold 行为随机对照。CI 为预注册首次窥视 ($n = 5{,}000$ warm 轮, seed 固定 bootstrap) 的配对 95% 区间。正差表示分形更好 (步数更少)。裁决: 等价——CI 完全落在 ±1 步等价界内。

指标	值
配对 warm 代价均值差 (固定 − 分形), n=5,000	−0.60 步
95% bootstrap CI	[−0.651, −0.548]
等价界	[−1, +1] 步
收敛窗口均值差, n=99,000	−0.15 步
warm 均值, 收敛段 (固定 / 分形)	8.96 / 9.11
cold 均值 (固定 / 分形)	31.44 / 31.53
越界率 (固定 / 分形)	0.10% / 0.00%
最终树节点	7 (封顶)

2 结果

2.1 修复后的预注册重跑判定: 配平计算量下等价

审计使结构优势处于不可判定状态 (节 2.2); 决定性检验需要三项与审稿人商定、且在运行前落实的修复。第一, 计算量必须配平: 七节点树每轮的梯度步数是单节点的数倍, 朴素重跑会把结构与计算量混淆。修复后的实现逐轮计数树中的总梯度步数, 并给固定学习器相同预算 (Forge commit `53e4938`)。第二, 判定规则必须在重跑开始前定死: 等价区间 ±1 步 (度量的整数步分辨率)、收敛窗口轮 ≥ 2000、最小 5,000 与最大 10,000 warm 轮且在 5,000 处一次窥视、以配对 bootstrap 95% 置信区间为裁决 (细节见 `PREREGISTRATION.md`)。第三, 运行必须可复现: 固定 seed(20261012) 与已提交的 trace。

重跑完成 200,000 轮 (100,000 warm、100,000 cold; warm 轮 ≥ 2000 者 $n = 99{,}000$)。在预注册的首次窥视 ($n = 5{,}000$) 处, warm 代价配对差 (固定 − 分形) 均值为 −0.60 步, 95% bootstrap CI 为 $[-0.651, -0.548]$——完全落在 $(-1, +1)$ 内, 即度量的分辨率内 (表 1)。按预注册规则, 此裁决为等价: 在一步或以上的代价分辨率下测不到结构优势。全收敛窗口确认了该窥视 ($n = 99{,}000$, 均值 −0.15), 四个时间段均值 (−0.16、−0.12、−0.18、−0.14) 表明差异平稳, 非早期瞬态。越界率低于预注册的 10% 上限 (固定 0.10%、分形 0.00%), cold 基线与预期的约 32 步一致 (31.44 / 31.53), 分形树本轮同样从 1 生长到 7 节点 (封顶)。

2.2 审计: 后裔从未被训练

本文早先版本声称一个边界结果: “无结构优势”。评审后对主实验实现的审计将该主张撤回为*这轮运行不可判定*, 因为三项发现表明这轮运行没有检验分形学习器。

后裔从未被训练。在 `design_daemon_fractal.py`(被审快照: commit `10ba961^`) 中, 每个节点

的优化器只对其自身网络与门控参数构造 ("opt = Adam(list(self.net.parameters()) + [self.gate])")。生长节点的子节点被追加到 `self.children`, 但从未加入任何父节点的优化器参数表, 主循环只对根调用 `train_step`。因此后裔的参数从不接收梯度步; 每个子节点唯一的操作是 warm-up 计数器递减。所生长的 "树" 是一个门控固定、随机初始化子网的根网络。

所宣称的稀疏调度从未执行。代码计算 `update_freq = D**depth` 并存储, 但没有任何调度决策查询它。深度相关的更新频率是文档, 而非行为。

评估不能按所述复现。 72,335 轮 trace 及其分析脚本不在仓库中; daemon 以墙钟时间为其 RNG 播种 (`int(time.time()) % 10000`); 重跑不复现报道的数字。

后果。配对长程差 (11.5 vs. 11.1 warm 步) 与三 seed、701 条记录比较, 比较的都是一个经训练的根对一个门控未训练子网的根——这一条件既不确认也不否认分形优势。长程适应与生长检测仍然成立 (节 2.3–2.4); 结构优势在节 **??** 的重跑之前一直不可判定。

2.3 两个根学习器的长程适应均真实成立

两个根都学习了并持续学习。warm 性能在前 1,000 轮从约 130 步降至大约 2,000 轮后的约 9 步, 并在剩余 70,000 轮中保持; cold 随机基线全程保持约 32 步 (表 1)。持续适应因此有效且稳定, 没有衰减。此结果独立于后裔训练缺陷: 它是根学习器的性质, 两个根都表现出它。

2.4 生长可操作, 但被封顶停止

分形树生长了六次 (第 46、57、73、80、87、94 轮), 从 1 节点到 7 节点, 然后停止。生长由相对衰减检测器驱动 (方法): 当验证损失的指数加权改进率低于该结构早期改进率的某个比例时, 生长后裔。达到七节点后, 检测器在剩余 72,000 轮中从未再触发。我们不将其归因于自主饱和: 七是实现中的硬安全上限, 因此生长是被封顶停止的, 而非涌现的均衡。没有封顶时树是否会继续生长, 未被检验。审计使读法更精确: 检测器与图突变在长程上工作, 但在被审运行中, 生长的组件从未作为学习器被发挥。

3 讨论

三句话必须分开, 而本文现在裁决了其中两句。"递归结构可塑性可实现且稳定" 被限定: 生长事件触发, 图结构突变, 但在被审运行中生长的组件从未学习, 所以我们只能说 **检测器与突变**工作, 而非生长的学习器。"结构生长改善性能" 是本文早先的主张, 现朝否定方向裁决: 在配平计算量下、在该确定性控制环境中, 预注册比较判为等价——结构生长在代价的一步分辨率下无可测优势。混淆 "树生长了" 与 "生长的组件学习了" 正是本次审计纠正的错误; 将两者分开是本文的方法论要点。

等价裁决是边界结果, 不是普遍化的许可。它适用于小模型、确定性重采样输入环境与配平梯度预算。分形分配论证 [5] 要求边际收益随深度急剧下降; 在数据有限的小学习器上它们可能不会,

而在专家间分割预算可能只会稀释每位专家的证据。分形组织在更大模型、非平稳环境或不配平预算下是否获益仍然开放——而本文的预注册协议正是这些主张应当被检验、而非被断言的模板。

方法论的教训是程序性的。分三步评估结构生长:(i) 图是否能安全突变,(ii) 突变后学习器是否持续适应,(iii) 突变是否在配平计算量与数据下改善预先注册的指标。本文跑了全部三步; 第 (iii) 步需要修复实现并预注册规则, 而它在该 regime 下的答案是无可测优势。

4 相关工作

我们的设计处于基于优化的元学习 [1, 3]、持续学习整合 [2] 与分形分配论证的交汇点——后者根植于默里对分支网络最小功的分析 [6], 并在我们配套的 Lean 开发中形式化 [5]。我们将其作为动机而非预测; 本文的贡献是方法论的——一次看似干净的长程比较如何静默地未能检验其假设, 以及决定性检验需要什么——而非声称分形组织有益或有害。

5 方法

5.1 递归分形环架构

每个节点 v 持有一个预测器 $f_v(x;\theta_v)$, 并可有后裔 $\mathcal{C}(v)$。节点输出为凸组合,

$$y_v(x) = g_{v,0}\, f_v(x;\theta_v) + \sum_{u\in\mathcal{C}(v)} g_{v,u}\, y_u(x), \qquad g_{v,j}\ge 0, \quad \sum_j g_{v,j} = 1, \tag{1}$$

门控由 softmax 产生。后裔不会立即被信任: 它们在进入父节点混合之前被独立预热, 这防止了 “死子节点” 失效——零初始化门控给予子节点零贡献, 因此零梯度。根节点每轮更新; 深度 d 的节点以 D^{-d} 的频率更新, 稀疏因子 D(我们用 $D=4$)。如审计所示, 该稀疏调度在部署代码中被指定但未被执行。

5.2 生长规则

生长由验证损失的相对衰减触发。设 $\bar{\imath}_t$ 为指数加权改进率, $\imath_0$ 为该结构早期平均改进率。当 $\bar{\imath}_t/\imath_0$ 连续多次观测低于阈值 (部署运行中为 0.25) 时, 生长一个后裔; 检测器在生长后重置。干净损失过滤器排除安全惩罚值, 因为惩罚尖峰不是结构瓶颈的证据。

5.3 控制环境

我们由双流环模型装配一个确定性 μ-动力学控制器:

$$\mu_{t+1} = \mu_t + \eta_t(1-\mu_t), \qquad \eta_t = \eta_{\text{ext}} + (2\lambda - \lambda^2)(1-\mu_t), \tag{2}$$

其中 η_{ext} 是外部驱动, λ 是收敛参数。任务是达到 $\mu \ge 0.999$(工作窗口) 而不越过 $\mu_{\text{ceil}} = 1 - m_e/m_i \approx 0.999780568$ (安全上限)。代价是到达窗口的步数; 越界是失败。环境是确定性的, 有清晰

的安全边界, 并且是重采样的: 每轮抽取新的 $\mu_0 \sim U(0.01, 0.8)$。我们将其描述为重采样而非漂移: 从控制点到代价的映射是固定的, 因此学习器面对的是输入重采样而非变化的任务。它是方法研究的基准, 而非任何实验性反引力装置的证据; λ 在上游模型中仍是输入缺口。

5.4 配对长程协议

每轮两个学习器看到相同的 μ_0。每个从自身经验选择控制点 ($(\eta_{\text{ext}}, \lambda)$ 的 20×10 网格上的 UCB), 执行环境, 并从最近经验滑动窗 (容量 400) 更新参数。奇轮为 cold 随机对照, 偶轮为 warm 推荐。部署运行使用 72,335 轮, 配失败时重启 daemon 的监督器; 决定性重跑使用 200,000 轮、seed 20261012 与配平计算量修复。如节 2.2 所述, 部署实现未将后裔参数纳入任何优化器, 因此协议描述是预期设计; 决定性重跑执行的是修复后的设计。

5.5 配平计算量修复与预注册判定规则

修复 (Forge commit `53e4938`) 使每个 `train_step` 返回其总梯度步数; 每轮, 固定学习器获得与分形树本轮相同的梯度步数, 结构与计算量不再混淆。判定规则在重跑开始前定死 (`PREREGISTRATION.md`): 收敛段 (warm 轮 ≥ 2000) 的配对 warm 代价差 (固定 $-$ 分形); 等价区间 ± 1 步; 配对 bootstrap 95% CI(10,000 次重采样, seed 固定); 裁决为等价 / 分形更优 / 固定更优 / 未决, 在 $n = 5{,}000$ 处一次窥视, 若仍未决则在 $n = 10{,}000$ 处停止, 不再追加样本 (防止持续窥视)。

5.6 塑造设计的失败分析

四个失败值得记录。(i) 绝对 "无改进" 生长检测器在浅层网络上从不触发 (它们缓慢地永远改进); 相对衰减检测器修复了它。(ii) 零初始化的子门控产生死子节点; 均匀门控初始化加预热阶段修复了它。(iii) 生长一层而不重新初始化逐参数步长元参数, 损害了快速适应环, 因此结构生长与元参数生长不能视为独立操作。(iv) 标准 RSI 指标不适用于单调改进的损失轨迹 (单侧增量使 RSI $\equiv 100$), 因此此处该词用于 "递归自我改进", 而非金融指标。

数据与代码可用性

被审实现、修复与分析脚本在 HUSHFUSION Forge 仓库中 [4]。被审快照为 commit `10ba961^`(子节点未训练); 修复后的配平计算量版本为 commit `53e4938`。决定性重跑 trace 为 `oml_daemon_fractal_matched_20261012.jsonl` (200,000 轮, seed 20261012; 36,151,557 字节; md5 `edc0f8e78fb0527d29d151222473f26b`; 最后写入 2026-10-12T03:11 UTC), 由 `paper/analyze_matched.py` 分析; 预注册、判定规则与裁决见 `PREREGISTRATION.md`。写作标准见 `WRITING-STANDARD.md`。

参考文献

[1] Chelsea Finn, Pieter Abbeel, and Sergey Levine. Model-agnostic meta-learning for fast adaptation of deep networks. In *Proceedings of the 34th International Conference on Machine Learning (ICML)*, pages 1126–1135, 2017.

[2] James Kirkpatrick, Razvan Pascanu, Neil Rabinowitz, Joel Veness, Guillaume Desjardins, Andrei A. Rusu, Kieran Milan, John Quan, Tiago Ramalho, Agnieszka Grabska-Barwinska, et al. Overcoming catastrophic forgetting in neural networks. *Proceedings of the National Academy of Sciences*, 114(13):3521–3526, 2017.

[3] Zhenguo Li, Fengwei Zhou, Fei Chen, and Hang Li. Meta-SGD: Learning to learn quickly for few-shot learning. *arXiv preprint arXiv:1707.09835*, 2017.

[4] Yuanjie Liu. HUSHFUSION Forge: design search, knowledge reuse, and continual-learning daemons. `https://github.com/logos-42/hushfusion-forge`, 2026. Long-horizon fracta-loop trace and reproduce scripts.

[5] Yuanjie Liu. LmPrinciple: Fractal allocation theorems for diminishing-return structures. `https://github.com/logos-42/lm-principle`, 2026. Lean formalization: Fractal.lean, prefix_allocation_optimal, fractal_beats_uniform.

[6] Cecil D. Murray. The physiological principle of minimum work: I. The vascular system and the cost of blood volume. *Proceedings of the National Academy of Sciences*, 12(3):207–214, 1926.